

$$N1 \quad L = -\frac{1}{n} \sum_{i=1}^n (y_i \cdot \log \hat{y}_i + (1-y_i) \cdot \log(1-\hat{y}_i))$$

$$\frac{\partial L}{\partial w_j} = -\frac{1}{n} \sum_{i=1}^n \left(\frac{y_i}{\hat{y}_i} \cdot \hat{y}_i \cdot (1-\hat{y}_i) \cdot x_{ij} - \right.$$

$$\left. - \frac{(1-y_i)}{1-\hat{y}_i} \cdot (1-\hat{y}_i) \cdot \hat{y}_i \cdot x_{ij} \right) =$$

$$= -\frac{1}{n} \sum_{i=1}^n x_{ij} (y_i - y_i \cdot \hat{y}_i - \hat{y}_i + y_i \cdot \hat{y}_i) =$$

$$= -\frac{1}{n} \sum_{i=1}^n x_{ij} (y_i - \hat{y}_i) \quad \text{— производная по } j\text{-ому весу}$$

$$\text{Тогда } \frac{\partial L}{\partial w} = -\frac{1}{n} \begin{pmatrix} \sum_{i=1}^n x_{i0} (y_i - \hat{y}_i) \\ \sum_{i=1}^n x_{i1} (y_i - \hat{y}_i) \\ \vdots \\ \sum_{i=1}^n x_{id} (y_i - \hat{y}_i) \end{pmatrix} = -\frac{1}{n} \sum_{i=1}^n x_i (y_i - \hat{y}_i)$$

вектор

можно записать так

$$\text{Если } Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \hat{Y} = \begin{pmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{pmatrix} \text{ то } \frac{\partial L}{\partial w} = -\frac{1}{n} \cdot X^T \cdot (Y - \hat{Y}) \leftarrow \text{матричный вид}$$

N2 M моделей

$$\hat{y}_m(x) = f(x) + \epsilon_m(x) \Rightarrow \epsilon_m(x) = \hat{y}_m(x) - f(x)$$

$$\hat{y}_{bag}(x) = \frac{1}{M} \sum_{m=1}^M \hat{y}_m(x)$$

ошибка бэггинга;

$$E_{bag} = E[(\hat{y}_{bag}(x) - f(x))^2]$$

средняя ошибка всех моделей:

$$E_{av} = \frac{1}{M} \sum_{m=1}^M E[(\hat{y}_m(x) - f(x))^2]$$

$\epsilon_{m_0} \cdot \epsilon_{m_1} = 0$, т.к. ошибки независимы
 $m_0 \neq m_1$

$$E[x+y] = E[x] + E[y]$$

$$\epsilon_{bag}(x) = \hat{y}_{bag}(x) - f(x) = \frac{1}{M} \sum_{m=1}^M (f(x) + \epsilon_m(x)) - f(x) = \frac{1}{M} \sum_{m=1}^M \epsilon_m(x)$$

$$E_{av} = \frac{1}{M} \sum_{m=1}^M E[\epsilon_m^2(x)]$$

Раскроем скобки, зная $\epsilon_{m_0} \cdot \epsilon_{m_1} = 0$

$$E_{bag} = E[\epsilon_{bag}^2(x)] = E\left[\frac{1}{M^2} \left(\sum_{m=1}^M \epsilon_m(x)\right)^2\right] = \frac{1}{M^2} \left(E\left[\sum_{m=1}^M \epsilon_m^2(x)\right] \right) =$$

$$= \frac{1}{M^2} \sum_{m=1}^M E[\epsilon_m^2(x)] = \frac{1}{M} E_{av}$$

№3 используя часть условия из 2 задачи

Пусть L - выпуклая функция ошибки

Тогда по неравенству Йенсена:

$$L(a_1 x_1 + \dots + a_n x_n) \leq a_1 L(x_1) + \dots + a_n L(x_n), \quad a_i - \text{положительные числа}$$

В частности $a_i = \frac{1}{n}$

$$L\left(\frac{x_1 + \dots + x_n}{n}\right) \leq \frac{L(x_1) + \dots + L(x_n)}{n}$$

$$\sum_{i=1}^n a_i = 1$$

$$E_{\text{bag}} = \frac{1}{M} \sum_{m=1}^M E_m(x)$$

Ошибка Джинна:

используем: $E[f(x)] \geq E[g(x)]$
 $f(x) \geq g(x)$

$$E_{\text{bag}} = E[L(E_{\text{bag}}(x))] = E\left[L\left(\frac{\sum_{m=1}^M E_m(x)}{M}\right)\right] \leq E\left[\sum_{m=1}^M L(E_m(x))\right] \cdot \frac{1}{M} =$$

$$= \frac{1}{M} \sum_{m=1}^M E[L(E_m(x))] = E_{\text{av}} \quad \text{Итого } E_{\text{bag}} \leq E_{\text{av}} \quad \blacktriangle$$

№4

$$L(y, \hat{y}_k(x)) = -\frac{1}{n} \sum_{i=1}^n (y_i \log \hat{y}_k(x_i) + (1-y_i) \log (1-\hat{y}_k(x_i))) \quad \text{берем произвольную по поводу}$$

$$S(x_i) = -\frac{\partial L(y, \hat{y}_k(x_i))}{\partial \hat{y}_k} = +\frac{1}{n} \left(\frac{y_i}{\hat{y}_k(x_i)} - \frac{1-y_i}{1-\hat{y}_k(x_i)} \right) = \frac{+1}{n} \left(\frac{y_i - \hat{y}_k(x_i)}{\hat{y}_k(x_i)(1-\hat{y}_k(x_i))} \right)$$

• S - вектор остатков для n объектов подвыборки $x^{(k+1)}$ искомый остаток

• мы уже построили модель из k деревьев, теперь надо

добавить $k+1$: мы его строим минимизируя функцию

потерь MSE $\min_{b_{k+1}} (b_{k+1}(x^{(k+1)}) - S)^T (b_{k+1}(x^{(k+1)}) - S) \rightarrow \min$ (на подвыборке b_{k+1} к $x^{(k+1)}$)

b_{k+1} - прогноз $k+1$ дерева. • Далее обновим композицию алгоритмов:

$$\hat{y}_{k+1}(x^{(k+1)}) = \hat{y}_k(x^{(k+1)}) + \gamma_{k+1} b_{k+1}(x^{(k+1)})$$

Далее подбираем оптимальный $\gamma_{k+1} \Rightarrow$

$$\gamma_{k+1} = \arg \min_{\gamma} \sum_{i=1}^n L(y_i; \hat{y}_k(x^{(k+1)}) + \gamma b_{k+1}(x^{(k+1)}))$$

композиция алгоритмов обновлена, можно добавлять еще деревья пока не достигнем какого-то критерия останова

Функция для обучения нового дерева:

$$(b_{k+1}(x^{(k+1)}) - S)^T (b_{k+1}(x^{(k+1)}) - S) \rightarrow \min_{b_{k+1}} \quad \text{или} \quad \sum_{i=1}^n \left((b_{k+1}(x_i^{(k+1)}) - S_{k+1}(x_i)) \right)^2 \rightarrow \min_{b_{k+1}}$$

n объектов - выборка

метод бутстрапа с повторением: n раз берем объекты из выборки (можно повторяющиеся) и получаем подвыборку

возьмем какой-то элемент, вероятность, что он не будет в подвыборке: $\left(\frac{n-1}{n}\right)^n \xrightarrow[n \rightarrow \infty]{} \left(\frac{1}{e}\right)$ (из Матана-1)

т.к. n большой

(вероятность выбора этого элемента на каждом отдельном шаге равна $\frac{1}{n}$, значит не выбора: $\frac{n-1}{n} = 1 - \frac{1}{n}$, и на n -ом шаге не выбираем)

Итого, вероятность, что какой-то элемент будет в выборке: $1 - \frac{1}{e}$, но т.к. события "выбора элементов" независимы друг от друга, то в среднем в подвыборке будет $n \cdot \left(1 - \frac{1}{e}\right)$ элементов, а процент: $\frac{n \cdot \left(1 - \frac{1}{e}\right)}{n} \approx 100\% \approx 63\%$ ▲